Práctica 1: Módulos

LIN - Curso 2021-2022

J.C. Sáez
High Performance Computing Division
ArTeCs Group
Universidad Complutense de Madrid

Contenido

Contenido

Práctica 1: Módulos

Objetivos

1. Familiarizarse con las siguientes abstracciones de Linux:
   - Módulos
   - Sistema de ficheros /proc
   - Listas enlazadas en el kernel
   - Gestión básica de memoria dinámica en el kernel
   - Depuración con Ftrace
2. Afrontar las dificultades de la programación en espacio de kernel

Contenido

Ejercicios I

Ejercicio 1

- `printk()` es un mecanismo de logging. 8 niveles de prioridad (`<linux/kernel.h>`)
  - ¿Qué diferencia encuentras entre KERN_INFO y KERN_ALERT?

Ejercicio 2

- La función de carga de los módulos de ejemplo devuelve 0 ¿qué ocurre cuando se devuelve un número negativo?

Ejercicios II

Ejercicio 3

- Estudiar el mecanismo de paso de parámetros a módulos del kernel
  - `<linux/moduleparam.h>`
  - Ejemplo 2.7 de *Linux Kernel Module Programming Guide* (módulo `hello-5`)

Ejercicio 4

- Los comandos básicos de gestión de módulos (`lsmod`, `insmod`, etc.) no son ejecutables independientes, sino enlaces simbólicos a la utilidad `kmod`.
  1. Verifica que estos comandos son en realidad enlaces simbólicos usando `stat`
  2. Intenta obtener un listado de los módulos del kernel que están cargados invocando `kmod` en lugar de `lsmod`.
     - Pista: Consultar la salida de `kmod -h`

Ejercicios III

Ejercicio 5

- Estudiar la implementación del módulo 'clipboard', que exporta una entrada /proc
  - Al cargar/descargar el módulo se creará/eliminará una entrada clipboard en el sistema de ficheros virtual /proc
  - La entrada clipboard puede emplearse como un portapapeles (*clipboard*) del sistema

Contenido

Ftrace

- Herramienta de depuración/inspección del kernel Linux
- Se usa realizando lecturas y escrituras en un conjunto de entradas en el sistema de ficheros *debugfs*
  - Directorio: `/sys/kernel/debug/tracing`
  - Sólo el usuario `root` puede configurar/usar `ftrace`
- Consta de un conjunto de *tracers*
  - `nop`
  - `function`
  - `function_graph`
  - ...
- Documentación de ftrace
  - https://www.kernel.org/doc/Documentation/trace/ftrace.txt

Montar debugfs para poder usar ftrace

- Las entradas de ftrace sólo estáran accesibles si:
  1. Kernel compilado con soporte de ftrace (`CONFIG_FTRACE=y`)
  2. … y debugfs está montado (en Debian 10 lo está por defecto)
     - `mount -t debugfs nodev /sys/kernel/debug`

Montando debugfs (si no estuviera ya montado)

```
kernel@debian:~$ sudo -i
[sudo] password for kernel:
root@debian:~# ls /sys/kernel/debug/tracing
ls: cannot access /sys/kernel/debug/tracing: No such file or directory
root@debian:~# ls
root@debian:~# mount -t debugfs nodev /sys/kernel/debug
root@debian:~# cd /sys/kernel/debug/tracing
root@debian:/sys/kernel/debug/tracing# ls
available_events            dyn_ftrace_total_info  kprobe_profile
saved_cmdlines       set_ftrace_pid      stack_trace_filter  tracing_cpumask
available_filter_functions  enabled_functions      max_graph_depth
saved_cmdlines_size  set_graph_function  trace
tracing_max_latency       available_tracers   events options
set_event            set_graph_notrace   trace_clock         tracing_on
...
```

Entradas básicas de Ftrace

- Entradas básicas en `/sys/kernel/debug/tracing`

Entrada	Descripción
`tracing_on`	Permite activar/desactivar ftrace o consultar estado actual. Escribir la cadena "1" para activar ftrace o "0" para desactivarlo.
`trace`	Al leer de esta entrada se muestran los mensajes almacenados en los *buffers* de ftrace (un *buffer* por CPU)
`trace_pipe`	Similar a `trace`, pero además los buffers se vacían al mostrar su contenido (semántica productor/consumidor)
`available_tracers`	Lista el conjunto de *tracers* disponibles
`current_tracer`	Permite consultar/modificar el *tracer* activo leyendo/escribiendo en la entrada
`available_filters`	Lista el conjunto de funciones del kernel o de los módulos cargados que pueden "filtrarse" al usar el tracer `function`.
`set_ftrace_filter`	Permite establecer la función (o funciones) para las que ftrace insertará un mensaje en el buffer cuando éstas sean invocadas.

nop tracer y trace_printk()

- *Tracer* por defecto en el kernel
- Captura únicamente los mensajes que el kernel o los módulos imprimen con la función `trace_printk()`

trace_printk()

- Para usar `trace_printk()` desde un módulo del kernel ...
  - `#include <linux/ftrace.h>`
- Uso similar a `printf()`, pero mensaje se inserta en buffer interno de ftrace
- Mucho más eficiente que `printk()`. Además, si ftrace está desactivado, no tiene efecto (modo *silencioso*)

Ejemplo de uso de `nop` tracer (1/4)

- Modificaremos el módulo de ejemplo `clipboard` para que muestre un mensaje con `trace_printk()` y capturaremos la salida con ftrace

Adiciones en clipboard.c (en verde)

```
#include <linux/vmalloc.h>
#include <asm-generic/uaccess.h>
#include <linux/ftrace.h>
...
static ssize_t clipboard_write(struct file *filp, const char __user *buf, size_t len, loff_t
      *off) {
...

  clipboard[len] = '\0'; /* Add the `\0' */
  *off+=len;          /* Update the file pointer */

  trace_printk("Current value of clipboard: %s\n",clipboard);

  return len;
}
...
```

Ejemplo de uso de `nop` tracer (2/4)

- Compilar y cargar el módulo

Terminal

```
kernel@debian:/tmp/FicherosP1/Clipboard$ make
make -C /lib/modules/5.10.45-lin/build M=/tmp/FicherosP1/Clipboard modules
make[1]: se entra en el directorio `/usr/src/linux-headers-5.10.45-lin'
  CC [M]  /tmp/FicherosP1/Clipboard/clipboard.o
  Building modules, stage 2.
  MODPOST 1 modules
  CC      /tmp/FicherosP1/Clipboard/clipboard.mod.o
  LD [M]  /tmp/FicherosP1/Clipboard/clipboard.ko
make[1]: se sale del directorio `/usr/src/linux-headers-5.10.45-lin'
kernel@debian:/tmp/FicherosP1/Clipboard$ sudo insmod clipboard.ko
[sudo] password for kernel:
kernel@debian:/tmp/FicherosP1/Clipboard$
```

Ejemplo de uso de `nop` tracer (3/4)

- Abriremos 2 terminales
  - (Primer terminal - root)
    1. Asegurarse que ftrace y nop tracer activos
    2. Leer de la entrada `trace_pipe` (bloqueante)
  - (Segundo terminal)
    1. Escribir la cadena "Test" en la entrada `/proc/clipboard`
    2. Escribir la cadena "Something" en la entrada `/proc/clipboard`
- Las acciones realizadas en el segundo terminal harán que se muestren mensajes por el primero (salida de `cat trace_pipe`)

Ejemplo de uso de nop tracer (4/4)

Terminal 1

```
root@debian:/sys/kernel/debug/tracing# cat current_tracer
nop
root@debian:/sys/kernel/debug/tracing# cat tracing_on
1
root@debian:/sys/kernel/debug/tracing# cat trace_pipe
            bash-16182  [000] ....  1065.269409: clipboard_write:
            Current value of clipboard: Test

            bash-16182  [000] ....  1100.023458: clipboard_write:
            Current value of clipboard: Something
```

Terminal 2

```
kernel@debian:/tmp/FicherosP1/Clipboard$ echo "Test" > /proc/clipboard
kernel@debian:/tmp/FicherosP1/Clipboard$ echo "Something" > /proc/clipboard
kernel@debian:/tmp/FicherosP1/Clipboard$
```

ArTeCS

Tracer `function`

- Vuelca un "mensaje" en el buffer de ftrace cuando se ejecuta cierta función del kernel
  - Permite ver qué funciones se invocan sin modificar el código del kernel (o de un módulo)
- Soporta filtros de funciones
  - Escribir nombre(s) de funcion(es) a trazar en `set_ftrace_filter`
  - El listado de funciones que pueden seleccionarse se puede obtener leyendo de la entrada `available_filter_functions`
- Por defecto, no hay ningún filtro → ¡¡Se trazan todas las funciones (mucha sobrecarga)!!
  - Aconsejable desactivar temporalmente ftrace (`tracing_on`) hasta que se establezcan correctamente los filtros de funciones

Ejemplo de uso del tracer `function` (1/2)

- Usaremos ftrace para que nos avise cuándo se invoca la función `clipboard_read()` del módulo `clipboard`
  - No es preciso modificar el código para esto

Pasos (desde `/sys/kernel/debug/tracing` como `root`)

1. Desactivar temporalmente ftrace
   $ echo 0 > tracing_on
2. Activar function tracer y comprobar que se activó correctamente:
   $ echo function > current_tracer ; cat current_tracer
3. Preparar filtros de ftrace
   $ echo clipboard_read > set_ftrace_filter
4. Activar ftrace
   $ echo 1 > tracing_on

Ejemplo de uso del tracer `function` (2/2)

- Una vez configurado el tracer `function`, abrir 2 terminales
  - (Primer terminal - root)
    - Leer de la entrada `trace_pipe` (bloqueante)
  - (Segundo terminal)
    - Leer de la entrada `/proc/clipboard`

Terminal 1

```
root@debian:/sys/kernel/debug/tracing# cat trace_pipe
    cat-16406  [000] ....  3166.842845: clipboard_read <-proc_reg_read
    cat-16406  [000] ....  3166.844485: clipboard_read <-proc_reg_read
```

Terminal 2

```
kernel@debian:/tmp/FicherosP1/Clipboard$ cat /proc/clipboard
Something
kernel@debian:/tmp/FicherosP1/Clipboard$
```

¿Por qué `clipboard_read()` se invoca 2 veces?

Contenido

Especificación de la práctica

- Crear un módulo `modlist` que gestione una lista enlazada de enteros

```
struct list_head mylist; /* Lista enlazada */

/* Nodos de la lista */
struct list_item {
    int data;
    struct list_head links;
};
```

- El módulo permitirá al usuario insertar/eliminar elementos de la lista mediante la entrada `/proc/modlist`
  - Cuando el módulo se cargue/descargue se creará/eliminará dicha entrada
- La memoria asociada a los nodos de la lista debe gestionarse de forma dinámica empleando `vmalloc()` y `vfree()`
  - Al descargar el módulo → liberar memoria si lista no vacía

Especificación de la práctica

Operaciones soportadas por el módulo

1. Inserción al final de la lista
   - `echo add 10 > /proc/modlist`
2. Eliminación de la lista
   - `echo remove 10 > /proc/modlist`
   - *Borra todas las ocurrencias de ese elemento en la lista*
3. Impresión por pantalla de la lista
   - `cat /proc/modlist`
4. Borrado de todos los elementos de la lista
   - `echo cleanup > /proc/modlist`

- Se aconseja utilizar `sscanf()` para procesar los comandos del usuario

Ejemplo de ejecución

terminal

```
kernel@debian$ sudo insmod modlist.ko
kernel@debian$ cat /proc/modlist
kernel@debian$ echo add 10 >  /proc/modlist
kernel@debian$ cat /proc/modlist
10
kernel@debian$ echo add 4 >  /proc/modlist
kernel@debian$ echo add 4 >  /proc/modlist
kernel@debian$ cat /proc/modlist
10
4
4
kernel@debian$ echo add 2 >  /proc/modlist
kernel@debian$ echo add 5 >  /proc/modlist
kernel@debian$ cat /proc/modlist
10
4
4
2
5
```

Ejemplo de ejecución (cont..)

terminal

```
kernel@debian$ echo remove 4 > /proc/modlist
kernel@debian$ cat /proc/modlist
10
2
5
kernel@debian$ echo cleanup > /proc/modlist
kernel@debian$ cat /proc/modlist
kernel@debian$
```

Partes opcionales

- **(Opcional 1)** Modificar el módulo de la práctica para que la lista gestionada sea de cadenas de caracteres
  - La memoria de las cadenas debe reservarse con `vmalloc()`
  - NOTA: Se valorará positivamente la inclusión de sentencias de compilación condicional para mantener en un mismo fichero fuente las implementaciones del módulo con lista de enteros (básica) y lista de cadenas de caracteres (opcional)
    - Los símbolos de preprocesador se especifican con la opción -D, y a través de la variable de entorno EXTRA_CFLAGS
    - Ej. compilación: `make EXTRA_CFLAGS=-DPARTE_OPCIONAL`

```
#ifdef PARTE_OPCIONAL
... Fragmento de código específico para lista de cadenas...
#else
... Fragmento de código específico para lista de enteros...
#endif
```

Partes opcionales (cont.)

- **(Opcional 2)** Reimplementar la read callback de la entrada /proc empleando `seq_printf()` mediante la abstracción de `seq_files` de Linux
  - Aconsejable mantener un contador con el número de elementos de la lista

Ventajas del uso de `seq_file`:

- Soporte especial para recorrido de secuencias de elementos
- Gestión implícita del buffer de usuario
  - No requiere usar `copy_to_user()` ni `sprintf()`

Parte opcional 2 (documentación)

Documentación sobre `seq_files` para Linux 5.7.x y anteriores...

- Sección 10.2 “Professional Linux Kernel Architecture”
- The seq_file Interface (kernel docs)

Ejemplo implementación para Linux 5.10.x de entrada `/proc/cpuinfo`

- https://elixir.bootlin.com/linux/v5.10.60/source/fs/proc/cpuinfo.c#L12
- https://elixir.bootlin.com/linux/v5.10.60/source/arch/x86/kernel/cpu/proc.c#L177
- Cambios con respecto a versiones previas del kernel:
  1. Usar `struct proc_ops` en lugar de `struct file_operations` para entrada /proc
  2. Se ha de definir la callback `read_iter` en lugar de `read` en `struct proc_ops`

Entrega de la práctica

- A través del Campus Virtual
  - Hasta el 1 de octubre
- Aconsejable mostrar el funcionamiento antes de hacer la entrega

Estructura entrega (en un fichero comprimido .tar.gz o .zip)

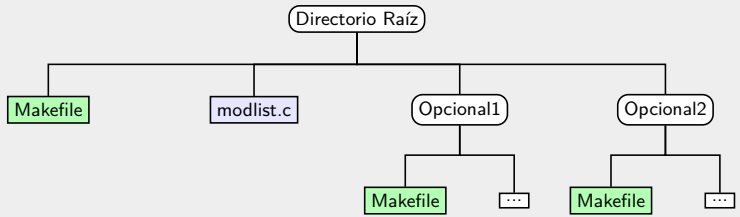

Licencia

LIN - Práctica 1: Módulos
Versión 2.5

Este documento (o uno muy similar) está disponible en https://cvmdp.ucm.es/moodle/course/view.php?id=20152